

Resumo de Métricas de Avaliação em Machine Learning

Este material resume as principais métricas usadas em problemas de CLASSIFICAÇÃO e REGRESSÃO, explicando o que cada uma mede e dando exemplos práticos de uso.

MÉTRICAS DE CLASSIFICAÇÃO

1. Accuracy (Acurácia)

Mede a porcentagem total de previsões corretas do modelo.

Interpretação: se Accuracy = 0,85, o modelo acertou 85% dos casos.

Uso típico: quando as classes estão balanceadas.

Exemplo de uso: classificação de imagens quando há quantidades parecidas de cada classe.

2. Precision (Precisão)

Indica, entre todos os exemplos previstos como positivos, quantos realmente são positivos.

Fórmula: Precision = VP / (VP + FP)

Interpretação: se Precision = 0,90, então 90% das previsões positivas estão corretas.

Uso típico: quando falsos positivos são caros.

Exemplo: detecção de fraude ou spam.

3. Recall (Sensibilidade)

Mostra quantos dos positivos reais o modelo conseguiu identificar.

Fórmula: Recall = VP / (VP + FN)

Interpretação: se Recall = 0,70, o modelo encontra 70% dos casos reais.

Uso típico: quando falsos negativos são críticos.

Exemplo: diagnóstico médico.

4. F1-score

É a média harmônica entre Precision e Recall, equilibrando as duas métricas.

Interpretação: valores altos indicam bom equilíbrio entre detectar positivos e evitar alarmes falsos.

Uso típico: dados desbalanceados.

Exemplo: classificação de clientes inadimplentes.

5. AUC – Area Under ROC Curve

Mede a capacidade do modelo de separar classes positivas e negativas, independentemente do limiar escolhido.

Interpretação:

1.0 = perfeito

0.5 = aleatório

Uso típico: comparação entre classificadores.

Exemplo: modelos de crédito ou risco.

6. Matriz de Confusão

Mostra em detalhes acertos e erros do modelo:

Verdadeiros Positivos, Verdadeiros Negativos, Falsos Positivos e Falsos Negativos.

Interpretação: ajuda a entender exatamente onde o modelo falha.

Uso típico: análise profunda de desempenho.

Exemplo: verificar se um modelo médico está deixando passar muitos doentes.

=====

MÉTRICAS DE REGRESSÃO

=====

7. MAE – Mean Absolute Error

Mede o erro médio absoluto entre valores reais e previstos.

Interpretação: se MAE = 10, o modelo erra cerca de 10 unidades em média.

Uso típico: quando se deseja interpretação direta do erro.

Exemplo: previsão de preços de imóveis.

8. RMSE – Root Mean Squared Error

Parecido com MAE, mas penaliza mais erros grandes.

Interpretação: erros grandes impactam fortemente o valor final.

Uso típico: quando grandes desvios são inaceitáveis.

Exemplo: previsão de demanda ou consumo de energia.

9. R² – Coeficiente de Determinação

Indica quanta variabilidade da variável alvo é explicada pelo modelo.

Interpretação:

R² = 0,75 significa que 75% da variação é explicada pelo modelo.

Uso típico: avaliar qualidade geral de modelos de regressão.

Exemplo: análise econômica ou financeira.

=====

RESUMO FINAL

Accuracy: percentual total de acertos.

Precision: confiabilidade das previsões positivas.

Recall: cobertura dos positivos reais.

F1: equilíbrio entre Precision e Recall.

AUC: capacidade de separação entre classes.

Matriz de Confusão: detalhamento completo dos erros.

MAE: erro médio absoluto em regressão.

RMSE: erro médio com penalização maior para desvios grandes.

R²: proporção da variância explicada pelo modelo.

Essas métricas são essenciais para selecionar, comparar e validar modelos em aplicações reais de ciência de dados e machine learning.